МЕТОДИЧЕСКОЕ ПОСОБИЕ

Анализ цифровых следов, стеганографии и стилометрии в PDF-документах на базе утилиты **GHOSTTRACE v0.1-Demo**

1. Введение и назначение инструмента

Электронные документы формата PDF часто содержат скрытую служебную информацию: имя автора, модель устройства, программное обеспечение, дату создания и редактирования. Кроме того, сам текст документа несет индивидуальные речевые особенности, позволяющие идентифицировать автора (стилометрия), а бинарная структура может скрывать встроенные данные (стеганография).

Скрипт **GHOSTTRACE v0.1-Demo** представляет собой учебно-практический инструмент на языке Python, предназначенный для проведения базового аудита безопасности PDF-файлов и удаления стандартных метаданных.

> **Основные задачи модуля:**
> - Оценка информационной энтропии бинарного файла для поиска аномалий.
> - Выявление и удаление словаря метаданных PDF-документа.
> - Базовый стилометрический анализ текста для оценки риска деанонимизации автора.

2. Установка и запуск

Для корректной работы программы требуется интерпретатор Python версии 3.8 или выше, а также сторонняя библиотека `pypdf` для чтения и перезаписи структуры PDF.

```
# Шаг 1. Установка необходимой зависимости
pip install pypdf

# Шаг 2. Запуск скрипта из терминала
python project_7EgFiz.py
```

После запуска программа запросит путь к целевому PDF-файлу. В результате работы в той же директории будет создан очищенный документ с суффиксом `_clean.pdf`.

3. Архитектура и алгоритмы работы

Логика скрипта разделена на три ключевые аналитические функции и управляющий цикл `main()`.

Функция	Входные данные	Назначение и возвращаемый результат
`calculate_entropy(data)`	`bytes` (сырые байты файла)	Вычисляет энтропию Шеннона (бит/байт) с округлением до 4 знаков.
`analyze_stylometry(text)`	`str` (извлеченный текст)	Возвращает словарь со средней длиной предложения, лексическим разнообразием и уровнем риска.
`sanitize_pdf(in, out)`	`str` (пути к файлам)	Пересобирает PDF без старых метаданных, возвращая исходные теги, энтропию и отчет стилометрии.

3.1. Вычисление энтропии Шеннона

Информационная энтропия измеряет степень случайности распределения байтов в файле (в диапазоне от `0.0` до `8.0` бит/байт). В коде используется классическая формула Шеннона:

```
H = - Σ p(x) * log2(p(x))
```

Где `p(x)` — вероятность появления конкретного байта `x` в файле. Значение выше `7.95` помечается скриптом как потенциальный признак шифрования или стеганографического вложения.

3.2. Стилометрический аудит текста

Алгоритм разбивает извлеченный текст на предложения (по знакам `.`, `!`, `?`) и выделяет слова кириллицы и латиницы с помощью регулярного выражения `[а-яА-Яa-zA-Z]+`. Далее рассчитываются два показателя:

- **Средняя длина предложения (`avg_sentence_len`):** отношение общего числа слов к количеству предложений.
- **Коэффициент лексического разнообразия (`lexical_diversity`):** отношение числа уникальных слов к общему количеству слов (индекс TTR — Type-Token Ratio).

Если средняя длина предложения превышает **18 слов**, а лексическое разнообразие выше **0.70**, скрипт присваивает тексту статус высокого риска деанонимизации.

3.3. Санитизация (очистка) PDF

Функция `sanitize_pdf` считывает страницы исходного файла через `PdfReader` и копирует их в новый объект `PdfWriter`. При этом исходный словарь метаданных (`Info`) не переносится, а заменяется единственным системным тегом `/Producer: GhostTrace Sanitized Engine v0.1`.

4. Технические ограничения и рекомендации по доработке

При использовании данного прототипа в реальных задачах информационной безопасности необходимо учитывать ряд архитектурных особенностей:

> **Критические нюансы текущей версии (v0.1-Demo):**
> - **Остаточные XMP-метаданные:** Простое копирование страниц удаляет словарь `/Info`, но может сохранить XML-потоки метаданных (XMP) и EXIF-данные внутри встроенных изображений.
> - **Ложные срабатывания энтропии:** Современные PDF используют сжатие потоков (FlateDecode) и формат JPEG для картинок, что естественно повышает энтропию до `7.96–7.99` без наличия стеганографии.
> - **Уязвимость обработки путей:** Метод `file_path.replace(".pdf", "_clean.pdf")` некорректно сработает, если расширение написано в верхнем регистре (`.PDF`) или строка `.pdf` встречается в имени папки. Рекомендуется использовать модуль `pathlib`.

5. Контрольные вопросы для самопроверки

1. Какое максимальное теоретическое значение может принимать энтропия Шеннона при побайтовом анализе файла и почему?
2. Почему высокий индекс лексического разнообразия (TTR) облегчает задачу атрибуции текста конкретному автору?
3. Какие скрытые данные могут остаться в PDF-документе после пересборки страниц через `PdfWriter` без дополнительной очистки потоков?
4. Как модифицировать формирование имени выходного файла в функции `main()`, чтобы избежать ошибок при работе с файлами в верхнем регистре (`.PDF`)?